Segmentación semántica de césped con CSIRO Biomass Seg

Informe de decisiones experimentos y aprendizajes

Campo	Detalle
Autor	Ojeda Fernandez Lisandro Carlos
Fecha	1 de octubre de 2026
Estado	Corrida completa ejecutada en Colab · E3 seleccionado por validation

Resumen del recorrido

El objetivo fue clasificar cada píxel válido de una fotografía RGB como césped o vegetación verde, suelo expuesto u otra vegetación. La salida de suelo se interpreta como una zona candidata a revisión; no estima superficie, biomasa ni tratamientos.

La primera decisión relevante ocurrió antes de entrenar. El ZIP de GrassClover disponible no contenía máscaras semánticas utilizables. En lugar de desactivar el control, busqué un reemplazo público y elegí CSIRO-Biomass-Seg. Verifiqué el archivo real: 357 imágenes, 357 máscaras, ningún par faltante, tamaños alineados y valores entre 0 y 5.

Comparé un baseline interpretable con una U-Net de encoder ResNet-34. E3, el modelo ajustado mediante fine-tuning, obtuvo el mejor resultado: mIoU de test 0,6976 y macro Dice 0,8095. La mejora frente a E1 mostró que la transferencia fue decisiva, sobre todo para la clase otra vegetación.

PRIORIDADES

Qué haría con más tiempo

Pondría el esfuerzo adicional primero en los datos y después en arquitecturas más complejas. El mayor riesgo no es la capacidad del modelo, sino el cambio entre pasturas de CSIRO y jardines fotografiados con celular.

Prioridad	Acción	Qué permitiría comprobar
1	Anotar fotografías locales por jardín, hora e iluminación	Generalización a sitios nuevos y ejecución de E4 y E5
2	Usar las 357 imágenes y repetir con varias semillas	Media, dispersión y sensibilidad de los resultados
3	Separar césped verde, seco, trébol, malezas y suelo	Reducir la ambigüedad creada por la clase Green
4	Comparar DeepLabV3+ o SegFormer pequeño	Costo de memoria e inferencia frente a precisión
5	Agregar incertidumbre, bordes y aprendizaje activo	Detectar casos dudosos y priorizar nuevas anotaciones

Separaría siempre por jardín, no por fotografía. También revisaría las máscaras antes de aumentar el tamaño del modelo: una arquitectura mayor no corrige etiquetas ambiguas. Para producción mediría tiempo de inferencia y calibración, además de IoU.

Decisión de compromiso

La corrida actual limita el conjunto público a 300 imágenes para ajustarse a Colab. Ese recorte reduce costo, pero deja sin cuantificar parte de la variación estadística. El informe final debería incluir más de una semilla si el tiempo de cómputo lo permite.

RECORRIDO

Investigación y elección del dataset

Busqué un dataset público con máscaras por píxel, pares inequívocos, clases relevantes, licencia explícita y tamaño manejable. GrassClover falló en el primer criterio dentro del archivo descargado. Relajar la validación sólo habría ocultado la ausencia de etiquetas.

Criterio	GrassClover disponible	CSIRO-Biomass-Seg
Máscaras por píxel	No encontradas	357 máscaras verificadas
Pares imagen máscara	No comprobables	357 de 357, sin faltantes
Semántica	No utilizable para esta descarga	Seis IDs documentados
Licencia	No resolvía el bloqueo técnico	CC BY-SA 4.0
Uso en Colab	No permite supervisión	ZIP de 477 MB manejable

Verificación realizada

No me limité a los nombres de carpeta. Abrí todas las máscaras, comprobé que fueran monocanal, comparé su tamaño con la imagen homónima y reuní los valores observados. El conjunto pasó estas pruebas con valores 0, 1, 2, 3, 4 y 5.

Compromiso semántico

CSIRO no entrega una clase explícita de maleza y Green no equivale necesariamente a césped residencial. Preferí una taxonomía conservadora: Clover se agrupa como otra vegetación, Green como césped o vegetación verde y Ground como suelo. Las regiones ambiguas se ignoran.

DATOS

Preparación y partición de datos

ID	Clase original	Clase objetivo	Razón
0	Background	Ignorar 255	Fuera del objetivo
1	Clover	Otra vegetación 2	Vegetación distinta del césped principal
2	Green	Césped 0	Aproximación disponible
3	Dead Matter	Ignorar 255	Ambigua para la taxonomía
4	Ground	Suelo expuesto 1	Correspondencia directa
5	Covering	Ignorar 255	Región no utilizable

Partición

Selecciono hasta 300 imágenes antes de dividir. Cada identificador se ordena con SHA-256 combinado con la semilla 42. La proporción objetivo es 70 por ciento train, 15 por ciento validation y 15 por ciento test. Los duplicados exactos se agrupan por hash y un sitio conocido queda en una sola partición.

Conjunto	Uso	Decisiones permitidas
Train	Ajustar parámetros y pesos de clase	Aumentos y optimización
Validation	Seleccionar umbral, checkpoint y parada	Comparar E1, E2 y E3
Test	Evaluación final reservada	Ningún ajuste

Transformaciones

Trabajo con patches de 512 por 512. Train recibe recortes, reflexiones, transformaciones geométricas y variaciones moderadas de iluminación. Imagen y máscara se transforman juntas; la máscara siempre usa vecino más cercano. Validation y test usan un recorte central determinista.

MODELO

Por qué usé una red neuronal

Una regla de color puede detectar vegetación cuando el verde está bien iluminado y el suelo contrasta. Por eso E0 combina HSV, Excess Green y morfología. Es una referencia rápida e interpretable.

Sombras, césped seco, trébol, suelo húmedo y cambios de cámara exigen contexto espacial. Una red convolucional puede aprender color, textura y relaciones de vecindad. Como la salida es una etiqueta por píxel, U-Net ofrece una estructura directa para recuperar detalle mediante conexiones de salto.

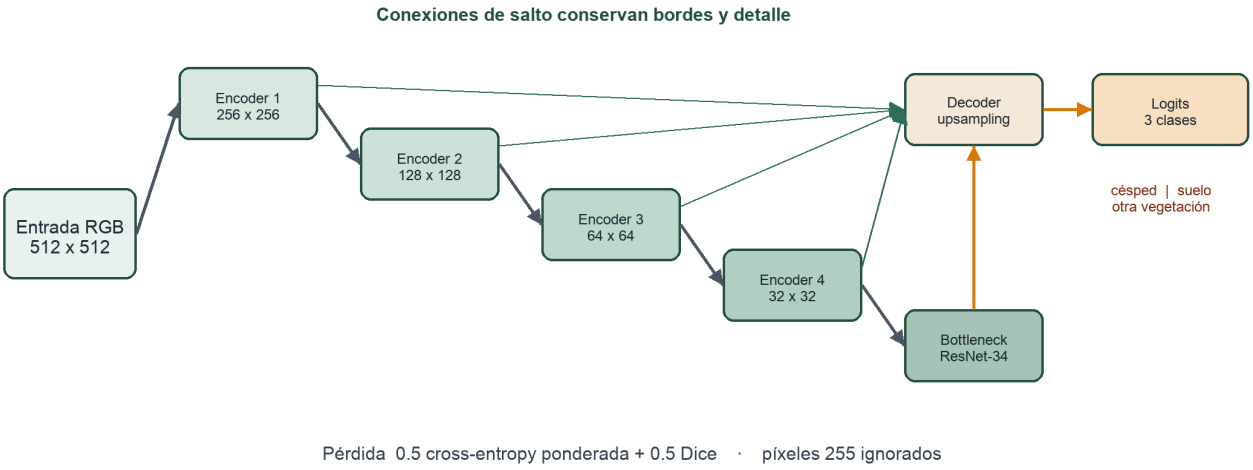


Figura 1 Arquitectura implementada y flujo de decisión

Decisiones de diseño

ResNet-34 equilibra capacidad y costo. La salida conserva logits para que cross-entropy sea numéricamente estable. La pérdida usa 0.5 cross-entropy ponderada y 0.5 Dice; el valor 255 queda fuera de ambas partes.

EVALUACIÓN

Diseño experimental y métricas

Experimento	Configuración	Pregunta
E0	HSV + Excess Green + morfología	Qué logra una regla simple
E1	U-Net ResNet-34 desde cero	Cuánto aprende sin transferencia
E2	Encoder ImageNet congelado	Valor inicial del preentrenamiento
E3	Fine-tuning desde E2	Beneficio de adaptar todo el encoder
E4	Mejor modelo público en test local	Magnitud del cambio de dominio
E5	Adaptación con train local	Recuperación con pocas etiquetas locales

Optimización

Uso AdamW, weight decay 1e-4, clipping 1.0 y mixed precision. E1 y E2 parten con learning rate 1e-3; E3 usa 1e-4 y ReduceLROnPlateau. Early stopping y checkpoints se controlan con mean IoU de validation. El batch inicial 2 baja a 1 si falta memoria CUDA.

Métricas

Métrica	Uso
Mean IoU de validation	Seleccionar checkpoint y comparar experimentos
IoU y Dice por clase	Detectar clases que el promedio oculta
Macro Dice	Resumen con igual peso por clase
Precision recall y F1 de suelo	Evaluar falsos avisos y suelo omitido
MAE de porcentaje	Medir error de composición por imagen

E0 es una referencia binaria. Test se reserva hasta cerrar la selección con validation.

RESULTADOS

Resultados y lectura de curvas

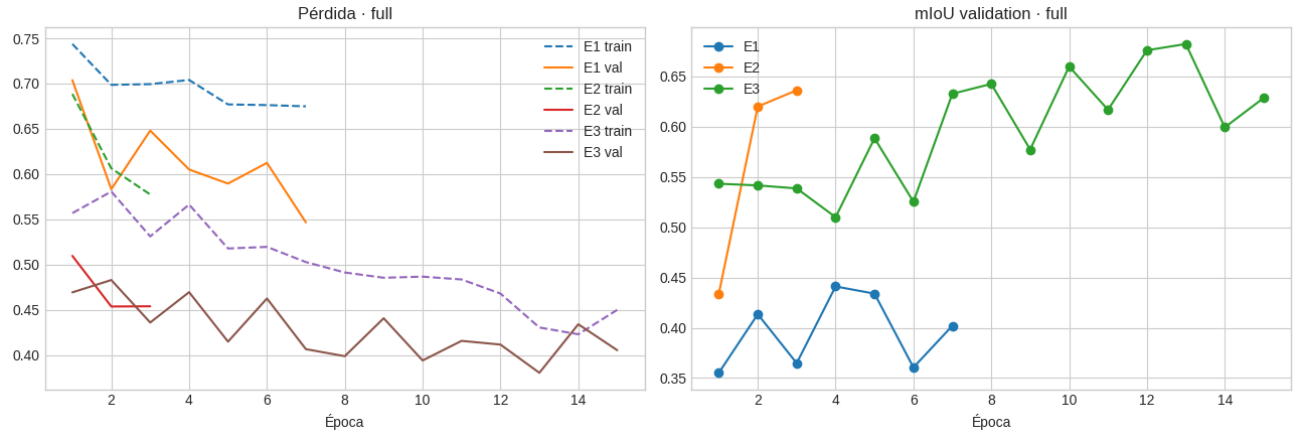


Figura 2 Pérdidas y mIoU de validation en la corrida completa

E1 fue inestable y alcanzó su mejor mIoU de validation en la época 4. E2 llegó a 0,6361 en sólo tres épocas, evidencia de que las representaciones de ImageNet aceleraron el aprendizaje. E3 necesitó una adaptación más gradual y alcanzó 0,6821 en la época 13. Después del máximo, validation mIoU cayó a 0,5993 y 0,6285, por lo que conservar el mejor checkpoint evitó usar un estado final peor.

Exp	Mejor val	Test mIoU	Macro Dice	F1 suelo	IoU otra veg
E0	IoU suelo 0,1332	No aplica	No aplica	0,2594	No aplica
E1	0,4411	0,5131	0,5928	0,8090	0,0333
E2	0,6361	0,6712	0,7913	0,8327	0,4540
E3	0,6821	0,6976	0,8095	0,8557	0,4699

Elegí E3 por validation antes de consultar test. En test superó a E2 por 0,0264 puntos de mIoU y a E1 por 0,1846. La diferencia más clara apareció en otra vegetación: su IoU pasó de 0,0333 en E1 a 0,4699 en E3.

DIFICULTADES

Lo que no funcionó

El dataset original no tenía las etiquetas necesarias

El ZIP de GrassClover contenía imágenes, pero la validación no encontró máscaras semánticas. No era un problema de la red. La solución fue inspeccionar la estructura y sustituir el dataset por CSIRO-Biomass-Seg.

El baseline simple quedó lejos de la red

E0 obtuvo IoU de suelo 0,1979 y F1 0,2594 en test. Sus reglas de color no resolvieron bien iluminación, texturas y vegetación seca. El resultado fue útil porque estableció una referencia concreta y justificó el costo de una red neuronal.

El entrenamiento desde cero ignoró una clase

E1 alcanzó mIoU 0,5131, pero la IoU de otra vegetación fue sólo 0,0333. El promedio ocultaba un colapso de clase. El preentrenamiento elevó esa IoU a 0,4540 en E2 y el fine-tuning a 0,4699 en E3.

La prueba de humo no servía para concluir

Con 18 imágenes, E1 produjo validation loss 125,6942 y mIoU 0,0322. No lo interpreté como rendimiento del modelo. La prueba cumplió otra función: comprobar carga, pérdida, backpropagation, checkpoints y uso de GPU antes de gastar tiempo en la corrida completa.

El fine tuning no mejoró de forma monotónica

E3 comenzó por debajo de E2 y osciló durante varias épocas. Recién en la época 13 alcanzó su mejor validation mIoU. Las épocas 14 y 15 empeoraron, un caso donde guardar el mejor checkpoint fue más importante que usar el último estado.

También hubo dificultades de implementación

Una edición parcial produjo un error de indentación y un pin antiguo de scikit-learn chocó con Colab. Reemplacé el bloque completo y usé un rango compatible. La corrida efectiva quedó registrada con Python 3.13.15, PyTorch 2.11.0 y CUDA 13.0.

Aprendizajes y conceptos aplicados

La semántica de las etiquetas forma parte del modelo

Aprendí que preparar datos no consiste sólo en convertir formatos. Tuve que decidir qué significa cada ID y qué afirmaciones permite. Usar 255 como ignore index fue una forma de expresar incertidumbre: Background, Dead Matter y Covering no aportaban una correspondencia segura con las tres clases objetivo.

El desbalance exige pérdidas y métricas adecuadas

En los 300 casos seleccionados, 64,52 por ciento de los píxeles eran césped, 6,56 por ciento suelo, 13,90 por ciento otra vegetación y 15,01 por ciento ignore. Una accuracy global habría favorecido la clase dominante. Por eso combiné cross-entropy ponderada con Dice y revisé IoU, Dice y F1 por clase.

Transfer learning y fine tuning cumplen funciones distintas

E2 mostró el valor de reutilizar representaciones visuales generales: con el encoder congelado llegó a validation mIoU 0,6361 en tres épocas. E3 mostró el paso siguiente: descongelar con learning rate menor permitió adaptar esas representaciones al dominio y elevar test mIoU a 0,6976.

Regularizar también es controlar el proceso

Los aumentos sincronizados redujeron dependencia de orientación e iluminación. AdamW y weight decay limitaron parámetros extremos; gradient clipping evitó actualizaciones inestables; mixed precision redujo memoria. Early stopping, scheduler y checkpoints controlaron cuándo y con qué estado terminar.

La evaluación necesita trazabilidad

La selección previa del subconjunto, los hashes, la semilla 42 y la división 210 45 45 hicieron repetible el experimento. Mantener test fuera de las decisiones evitó optimizar contra la respuesta final. Registrar versiones permitió interpretar la corrida dentro de su entorno real.

Una métrica alta no elimina el análisis de errores

La matriz de confusión mostró que E3 aún confundió otra vegetación con césped y que algunas regiones de césped pasaron a otra vegetación. Aprendí a mirar curvas, métricas por clase y ejemplos cualitativos juntos; ningún número aislado explica el comportamiento completo.

CIERRE

Alcance conclusión y referencias

Limitaciones

CSIRO representa pasturas y no necesariamente jardines residenciales. Green es una aproximación de césped. La corrida usa 300 imágenes y una semilla. E4 y E5 no se ejecutaron porque faltaron datos locales. Los porcentajes corresponden a píxeles válidos, no a superficie física ni biomasa.

Conclusión

La comparación respondió la pregunta principal. E0 mostró que las reglas simples no alcanzaban; E1 confirmó que entrenar desde cero era posible, pero fallaba en otra vegetación; E2 y E3 demostraron el aporte de transferencia y adaptación. E3 fue el mejor modelo con test mIoU 0,6976, macro Dice 0,8095 y F1 de suelo 0,8557. El resultado es válido para la partición pública utilizada y todavía requiere validación local.

Trazabilidad de la corrida

Elemento	Valor
Datos	300 imágenes · train 210 · validation 45 · test 45
Selección	E3 por validation · mejor época 13
Entorno	Python 3.13.15 · PyTorch 2.11.0+cu130 · CUDA 13.0
Pruebas	Assertions del notebook completadas correctamente

Referencias

1. Q. Yu y CSIRO. CSIRO-Biomass-Seg. kaggle.com/datasets/qiyuliaocsiro/csiro-biomass-seg
2. CSIRO. Image2Biomass Prediction. kaggle.com/competitions/csiro-biomass
3. Ronneberger, Fischer y Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. arXiv 1505.04597
4. He, Zhang, Ren y Sun. Deep Residual Learning for Image Recognition. arXiv 1512.03385
5. Creative Commons. Attribution-ShareAlike 4.0 International. creativecommons.org/licenses/by-sa/4.0/